

MLOps vs LLMOps vs GenAIOps

这不是三个名词，而是 AI 工程化对象的三次扩边界。

MLOps

to

GenAIOps

模型生产线 -> 应用运行时 -> 生成式系统
群

MLOps

data · train · eval · deploy · monitor

LLMOps

prompt · context · retrieval · tool · trace

GenAIOps

multi-modal · agents · tools · safety · assets

Technology Stack

Broad AI Infra: 1-4

Narrow AI Infra: 1

5 Applications 应用与体验

Chatbot / Copilot

Content Gen

Dev Tools

Enterprise SaaS

Multimodal Agent

4 Context & Agents 上下文与编排

Prompt

RAG

Tool Calling

Agent Workflow

Memory / Trace

3 Models & Serving 模型与服务

Foundation Models

Model APIs

Fine-tuned Models

Embeddings

Router / Cache

2 Data & Knowledge 数据与知识

Data Sources

Lakehouse

Documents

Embedding Index

Vector DB / Metadata

1 AI Infrastructure AI 基础设施

GPU / TPU / NPU

Storage / Network

Kubernetes / Ray

vLLM / TGI

Monitoring

Ops Lens

MLOps

管模型生产闭环

Data → Train → Evaluate
Deploy → Monitor → Feedback

LLMOps

管大模型应用运行闭环

Prompt / RAG / Tools / Trace
Eval / Safety / Cost / Latency

GenAI Ops

管生成式系统生产闭环

Multimodal Input / Generation
Assets / Provenance / Human Review

三代 Ops，管的对象越来越宽

MLOps 管模型生产，LLMOps 管应用行为，GenAIOps 管生成式系统群。

Act 1 · MLOps

把模型从实验带进生产，建立数据、训练、评测、部署、监控和回流闭环。

模型生产

Act 2 · LLMOps

把 prompt、context、retrieval、tool、trace、eval 纳入运行时控制。

应用行为

Act 3 · GenAIOps

把多模态、agent、工具动作、内容安全和生成资产纳入系统群治理。

系统群治理

同一个闭环，变量越来越宽

Input、Processing、Output、Feedback 都在变，所以工程体系必须扩边界。

	Input 输入变宽 features / prompt / multimodal signals	Processing 处理链路变长 pipeline / RAG / tools / workflow	Output 输出不再单一 prediction / answer / generated asset	Feedback 反馈更复杂 label / trace / review / asset lifecycle
MLOps	结构化特征、标签、训练集	特征流水线、训练、评测、serving	预测、分类、排序、分数	label、bad case、drift、重训触发
LLMOps	prompt、上下文、RAG、工具	prompt assembly、检索、tool call、trace	开放式文本、引用、工具结果	trace replay、人评、LLM judge、prompt/RAG 更新
GenAIOps	文本、图像、语音、视频、Agent 状态	多模态编排、workflow、生成 runtime	多模态内容、动作、生成资产	人审、red-team、安全版权、资产生命周期

同一条工程闭环没有消失，真正变化的是每一环要控制的变量越来越宽。

一个企业服务助手，走过三代 Ops

同一个项目，从意图分类，到 LLM 助手，再到多模态数字服务 Agent。

Running example

同一个企业服务助手，三代 Ops 管的对象一步步变宽。

01

MLOps

FAQ 意图分类 / 工单路由 / 答案排序

数据是历史工单、FAQ 标签、用户属性、点击和解决结果。输出是一个分类、排序或分数。

02

LLMOps

LLM 助手 + Prompt + RAG + LoRA + Trace

一次回答由 prompt、公司文档检索、工具调用和 trace 共同决定。坏答案要能回放和进入 eval set。

03

GenAI Ops

多模态数字服务 Agent

它能看截图、听语音、生成图文/视频指南、触发工具动作，并管理生成资产、来源和审批。

实验成功，不等于生产成功

实验环境里的高准确率，不能保证线上稳定服务用户。

实验环境

95% accuracy

Notebook / Lab

环境不一致

Dev 到 Prod 后依赖和运行条件变了

延迟不达标

线上请求有 SLA，不是离线跑分

数据漂移

用户行为和训练分布发生变化

不可复现

版本、数据、参数没有完整记录

无监控

客户投诉后才发现坏结果

更新太慢

坏例不能进入下一轮训练

MLOps 把风险变成工程门禁

它不是多画一条流程，而是让生产风险可复现、可监控、可回滚。

Environment

容器、依赖、运行环境一致

环境门禁

Performance

延迟、吞吐、资源预算

性能门禁

Data Drift

schema、分布、label 变化

数据监控

Reproduce

代码、数据、参数、artifact 可追踪

复现能力

Live Monitor

质量、延迟、日志、告警

线上观测


Update Loop

灰度、回滚、重训触发

更新闭环

MLOps 完整工程闭环

数据、模型、代码三类资产一起变化，所以必须有版本、门禁、监控和回流。



一句话

MLOps 让模型生产可复现、可发布、可监控、可回流。

数据先转起来

数据管理最终要服务训练集、评测集、特征和 **ground truth**。

采

采集 / 接入

存

湖仓 / 数据池

管

治理 / 血缘 / 权限 / 索引

算

清洗 / 特征 / 挖掘

用

训练 / 评测 / GT

数据不是为了存着，而是为了被训练、评测、回流和追踪。

训练、评测、模型管理

评测不是表格，它要调用推理环境，把模型真实跑一遍。

Training

任务调度 / GPU 集群 / 参数

Experiment Tracking

代码版本 / 数据版本 / 指标 / artifact

Inference Testbed

接近线上环境，把模型真实跑一遍

Evaluation

评测集 / 指标 / case 回归

Model Registry

版本管理 / 审批准入 / 发布门禁

部署、监控、回流

线上坏案例要回到数据中心，再变成下一轮训练和评测数据。

MLOps 管的是“模型生产链路”

把模型上线变成可复现、可追踪、可回滚的工程系统

主链路：从数据到上线



版本化

Data · Code · Model

改了什么、用了哪版，都能追踪

自动化

Pipeline · CI/CD

训练、测试、部署自动跑

可观测

Metrics · Logs · Drift

上线后能看见问题

MLOps 已覆盖

模型生产链路：数据、训练、评估、部署、监控

LLMOps 下一步还要治理

提示词 · 上下文 · 检索 · 工具调用

主线怎么看

从数据、训练、评测到部署，再看线上监控如何把坏案例送回下一轮。

关键对象

Deployment、Inference Serving、Monitoring、Data Feedback、Ground Truth。

这一页的结论

MLOps 不是训练完就结束，而是让模型生产形成可持续闭环。

数据、算力、模型

MLOps 和 LLMOps 都绕不开这三件事，但运行时变量开始走到台前。

数据

Data

算力

Compute

模型

Model

底座没变，但 LLM 应用把运行时变量推到了台前。

LLM 应用不是只调用模型

一次回答由请求、提示词、上下文、检索、工具、模型、缓存和反馈共同决定。

User Request

用户意图 / 文件 / 状态

Prompt + Context

任务策略 / 会话历史 / 上下文窗口

Retrieval + Tools

向量库 / 搜索 / DB / API

Model / Router / Cache

生成 / 路由 / 成本延迟控制

Response + Trace

答案 / 日志 / 回放 / 反馈

LLMOps 多管了哪些东西

Prompt、Embeddings、Vector Indexes、External Tools、Trace Logs 都变成 first-class artifacts。

Embeddings

语义表示

External Tools

系统动作

Prompt

behavior contract

Vector Indexes

知识入口

Eval Sets


行为回归

Trace Logs

请求回放

LLMOps 应用系统主链路

当 Prompt、RAG、工具和 Trace 都会改变一次回答，Ops 要管的是整条应用运行系统。



一句话


LLMOps 把运行时对象也纳入版本、评测、回放和门禁。

旧 MLOps 边界被撑开

不是 MLOps 没有评测和反馈，而是运行时对象也要版本化、监控和回归。

LLM 时代，旧边界被新变量撑开

不是 MLOps 失效，而是 Model Development 多了一组会影响上线的变量



边界变化

LLMOps 不是替代 MLOps，而是把 Prompt、Retrieval、Tool、Trace 等运行时变量纳入治理。

容易误解的点

MLOps 也有评测和反馈；LLMOps 新的是运行时对象高频变化、要版本化和回放。

这一页的结论

模型可以不变，但应用行为会变，所以运行时对象也要进入工程闭环。

LLMOps 管的是应用运行闭环

模型可以不变，但数据、提示词、检索、评测和反馈会持续变化。

LLMOps 管的是“应用运行闭环”

模型可以不变，但数据、提示词、检索、评测和反馈会持续变化



LLMOps 新增要管的对象

这些变化可能比模型版本更频繁，所以要进入开发、发布、监控、反馈闭环。

提示词

上下文

检索

工具调用

评测集

用户反馈

MLOps: 让模型生产可靠**LLMOps**: 让应用运行可控

内循环

开发阶段不断调 Model、Prompt、Retrieval、Tool、Guardrail。

发布门禁

上线前用 golden set、人评、LLM judge 和坏例回放挡住回退。

外循环

线上 Trace、Feedback、成本、延迟和安全信号回到下一轮。

LLMOps 要能回放一次坏答案

把线上问题变成可定位、可比较、可审批、可回滚的改动。

LLMOps 要能回放一次坏答案

把线上问题变成可定位、可比较、可审批、可回滚的改动

一次请求的证据链

先把答案怎么来的记录下来



从 trace 到发布门

不是凭感觉改 prompt，而是让每次改动经过评测和审批



能回放

知道坏答案怎么来的

能比较

知道改动前后谁更好

能预评测

上线前先过质量门

证据链

一次回答要留下用户问题、Prompt、检索文档、上下文、工具结果、答案和 Trace。

发布门禁

Trace 进入评测、CI、人工审批和灰度发布，改动不能靠感觉上线。

反馈闭环

监控结果继续回到下一轮评测和改动，让坏答案变成可回滚、可追踪的工程输入。

LLMOps 是控制力

真正的差异，是能不能把坏结果变成下一轮确定性。

Replay

坏结果能不能回放

Compare

版本变化能不能比较

Pre-Eval


上线前能不能挡住回退

Improve

坏例能不能进入下一轮

GenAIOps 生产系统主链路

当生成对象扩到多模态、Agent、工具动作和内容资产，Ops 要管的是一整组生成式系统。



一句话

GenAIOps 管的是多模态、Agent、工具动作和生成资产构成的系统群。

GenAIOps 管的是生成式系统生产链路

多模态数据、Agent 工作流、生成资产和安全反馈，都要进入可发布、可追踪、可回滚的工程闭环。

GenAIOps 管的是“生成式系统生产链路”

把多模态输入、Agent 工作流、生成资产和安全反馈变成可发布、可追踪、可回滚的工程闭环

主链路：从多模态数据到生成式服务



版本化

Prompt · RAG · Agent · Tool · Asset
生成系统里每个会改变结果的对象，都要能追踪

自动化

CI / Eval / Safety Gate / Release
上线前先跑评测门禁，不靠感觉发布

可观测

Trace · Cost · Risk · Provenance
上线后能看见质量、成本、风险和资产来源

主线怎么看

从多模态数据和应用组件开始，经过生成工作流、评测门禁、资产注册、发布和监控。

关键对象

Prompt、RAG、Agent、工具、生成资产和安全反馈都要进入门禁、监控和回流。

这一页的结论

GenAIOps 管的是生成式系统生产链路，而不是单个模型调用。

GenAIOps Step 1: Design

从设计、数据、组件、编排、生成、反馈和治理，把生成式系统群串起来。

01 **Design**

02 **Data**

03 **Components**

04 **Orchestrate**

05 **Generate**

06 **Feedback**

07 **Govern**

Application Design & Chaining

先定义用户要生成什么、链路怎么串、哪些组件参与。

把需求拆成可观测的生成式工作流，而不是一个黑箱 prompt。

GenAIOps Step 2: Data

从设计、数据、组件、编排、生成、反馈和治理，把生成式系统串联起来。

01 Design

02 Data

03 Components

04 Orchestrate

05 Generate

06 Feedback

07 Govern

Multi-modal Data Management

文本、图像、视频、语音、代码和用户反馈进入同一个数据治理面。

这里开始需要数据权限、来源、质量和资产血缘。

GenAIOps Step 3: Components

从设计、数据、组件、编排、生成、反馈和治理，把生成式系统群串起来。

01 Design

02 Data

03 Components

04 Orchestrate

05 Generate

06 Feedback

07 Govern

Generative Components

模型、agent、tool、RAG、workflow、guardrail 都变成可管理组件。

LLMOps 管 LLM 应用，GenAIOps 要管更宽的组件群。

GenAIOps Step 4: Orchestrate

从设计、数据、组件、编排、生成、反馈和治理，把生成式系统串联起来。

01 Design

02 Data

03 Components

04 Orchestrate

05 Generate

06 Feedback

07 Govern

Orchestration

把模型、工具、agent、prompt、检索、多模态输入输出和安全策略编排成系统。

把模型、工具、检索和安全策略串成一条可控链路。

GenAIOps Step 5: Generate

从设计、数据、组件、编排、生成、反馈和治理，把生成式系统群串起来。

01 Design

02 Data

03 Components

04 Orchestrate

05 Generate

06 Feedback

07 Govern

Generation Runtime

生成文本、图像、视频、语音或工具动作时，要同时管质量、成本、延迟和失败恢复。

生成过程本身成为生产系统。

GenAIOps Step 6: Feedback

从设计、数据、组件、编排、生成、反馈和治理，把生成式系统群串起来。

01 Design

02 Data

03 Components

04 Orchestrate

05 Generate

06 Feedback

07 Govern

Human Feedback & Evaluation

人评、自动评测、回放、偏好数据和安全反馈进入下一轮改进。

这一步把生成结果重新变成可训练、可评测、可治理的数据。

GenAIOps Step 7: Govern

从设计、数据、组件、编排、生成、反馈和治理，把生成式系统群串起来。

01 Design

02 Data

03 Components

04 Orchestrate

05 Generate

06 Feedback

07 Govern

Safety / Asset Governance

内容安全、版权、品牌风险、生成资产版本、审批和成本治理进入门禁。

GenAIOps 的关键是生成式系统群可治理。

生成式系统多了哪些管理对象

多模态输入输出、Agent 行为、工具动作、内容安全、生成资产版本和成本都要进入治理。

Multi-modal IO

图像、视频、语音、文本共同进入系统

Agent Behavior

计划、执行、调用工具、状态转移

Tool Actions

DB、API、浏览器、代码执行

Content Safety

版权、合规、品牌安全、策略风险

Generated Assets

生成内容版本、来源、复用和审批

Cost Governance

token、GPU、延迟、缓存和重试成本

同一条 pipeline，每一步都换了管理对象

Data、Adaptation、Evaluation、Deployment、Monitoring 没消失，只是每一步都变宽了。

Pipeline step	MLOps	LLMOps	GenAIOps
Data	features / labels / train-eval split	prompts / docs / embeddings / vector index	screenshots / voice / video / asset metadata
Adaptation	train classifier or ranker	prompt / LoRA / RAG / model-router update	workflow / agent / policy / asset pipeline tuning
Evaluation	accuracy / precision / recall / latency	groundedness / hallucination / tool correctness	multimodal consistency / safety / copyright / approval
Deployment	model image / endpoint / canary / rollback	LLM endpoint / prompt version / vector DB / tool registry	generation workflow / multimodal serving / approval layer
Monitoring	drift / bad prediction / label / retrain	trace replay / retrieval miss / prompt-tool failure	cross-modal mismatch / unsafe output / asset lifecycle

一句话总结 流程没有消失，只是管理对象从模型生产，扩到应用行为，再扩到生成式系统群。

没有必要与旧习惯做斗争。要养成新的习惯。

《心态制胜：超越评判、释放潜能的内在秘诀》

[美] W. 提摩西 · 加尔韦

谢谢大家的观看

请各位股东一键三连，我们下期再见，拜拜。

